Maestría en Inteligencia Artificial Aplicada

Materia: Proyecto Integrador

Profesor Titular: Dra. Grettel Barceló Alonso / Dr. Luis Eduardo Falcón Morales

Asesor de Proyecto: Dr. Carlos Alberto Villaseñor Padilla

Avance 2. Ingeniería de características

Equipo 10

David García Robles A01152606

David Nava Jiménez A01168501

José Antonio Hernández Hernández A01381334

Fecha: 11 de Mayo de 2025

Optimización de ventas en Nacional Monte de Piedad

Avance 2. Ingeniería de características

Contenido

Introducción

El presente documento tiene la finalidad de exponer el proceso de ingeniería de características aplicado sobre el dataset proporcionado por Nacional Monte de Piedad, como parte de un pipeline orientado al desarrollo de modelos de aprendizaje automático. Esta etapa es clave para transformar los datos crudos en variables numéricas útiles, interpretables y compatibles con algoritmos predictivos.

En esta fase, se llevaron a cabo diversas técnicas para enriquecer, transformar y codificar la información contenida en el conjunto de datos. Entre ellas, se aplicaron transformaciones logarítmicas, sobre variables numéricas con distribución sesgada como DIAS_ALMONEDA, con el objetivo de estabilizar su varianza y mejorar la capacidad explicativa de los modelos. Así mismo, se implementó la codificación One-Hot para convertir variables categóricas como RAMO, TIPO_PRENDA, ESTADO_SUCURSAL en representaciones numéricas binarias, evitando así la introducción de relaciones artificiales entre las categorías.

Además, se realizó un análisis detallado de correlaciones entre variables numéricas con el fin de identificar redundancias, relaciones lineales fuertes. Esta revisión permitió conocer variables altamente correlacionadas que podrían generar multicolinealidad, y por tanto, ser candidatas a ser eliminadas.

1.1 Carga de librerías y visualización inicial del DataFrame

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import re
```

```
df.head(5)
```

	SUCURSAL	ESTADO_SUCURSAL	CLAVE_OPERACION	OPERACION	PARTIDA	ORIGEN	DESCRIPCION_PARTIDA	GRAMAJE	KILATAJE	AVALUO_COMPLEMENTARIO	...	IVACOM_PASECOM	COM_EXHIBICION	IVACOM_EXHIBICION	INTERES_DEPRECUP	IVAINT_DEPRECUP	FECHA_MAX_DEP_RECUP	FECHA_CARGA	num_particion	imp_minusvalia	imp_cancelacion_in
0	1005	CIUDAD DE MÃ□XICO	VP	Venta al Publico	181615421	SIVA	176231504-1 ANILLO TIPO:DAMA DISEÃ□O:CABUJON D...	4	14	0	...	NaN	NaN	NaN	NaN	NaN	NaN	2024-05-03T05:01:25.637Z	202405.0	NaN	Na
1	1005	CIUDAD DE MÃ□XICO	VP	Venta al Publico	181616741	MIDAS	174275433-1 ANILLO ORO AMARILLO 14K PESO 1.60 ...	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	2024-05-03T05:01:25.637Z	202405.0	NaN	Na
2	1005	CIUDAD DE MÃ□XICO	VP	Venta al Publico	181616743	MIDAS	173896016-1 MEDIA CHURUMBELA ORO AMARILLO 14K...	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	2024-05-03T05:01:25.637Z	202405.0	NaN	Na
3	16	AGUASCALIENTES	VP	Venta al Publico	181662772	SIVA	1 COLLAR TIPO:ROSARIO DISEÃ□O:ESFERAS LISAS D...	23.9	10	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	2024-05-03T05:01:25.637Z	202405.0	NaN	Na
4	278	CIUDAD DE MÃ□XICO	VP	Venta al Publico	181809632	SIVA	1 ACCESORIOS TIPO:LLAVERO DISEÃ□O:GRABADO DE O...	12.4	8	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	2024-05-03T05:01:25.637Z	202405.0	NaN	Na

5 rows × 64 columns

Interpretación del DataFrame

Revisando a detalle los datos, identificamos que hay columnas que no contienen información, estas son las siguientes: GASTOSOPERACION, IVAINTERESDEPOSITO, IVAINTERESALMONEDA, IVAGASTOSOPERACION, IVA_DESEXT, FECHA_EMPENO_OK, FECHA_HORA_MOV_OK, FECHA_COMERCIALIZACION_OK, CUSTODIA, COM_ALMACENAJE, IVACOM_ALMACENAJE, COMPASE_COMERCIALIZACION, IVACOM_PASECOM, IVACOM_EXHIBICION, INTERES_DEPRECUP, IVAINT_DEPRECUP, imp_minusvalia, imp_cancelacion_int. Las cuales vamos a eliminar del dataset con la función drop de pandas.

```
df.drop(['AVALUO_COMPLEMENTARIO','GASTOSOPERACION', 'IVAINTERESDEPOSITO', 'IVAINTERESALMONEDA',
'IVAGASTOSOPERACION', 'IVA_DESEXT',
              'FECHA_EMPENO_OK', 'FECHA_HORA_MOV_OK', 'FECHA_COMERCIALIZACION_OK', 'CUSTODIA',
'COM_ALMACENAJE',
              'IVACOM_ALMACENAJE', 'COMPASE_COMERCIALIZACION', 'IVACOM_PASECOM', 'IVACOM_EXHIBICION',
              'INTERES_DEPRECUP', 'IVAINT_DEPRECUP', 'imp_minusvalia', 'imp_cancelacion_int'],
axis=1,inplace=True)
```

Adicional, encontramos instancias que no tienen valores (NaN) dentro del dataset, por lo que también eliminamos las instancias que tienen al menos 5 valores no nulos.

```
df = df.dropna(thresh=5)                                                    # Mantiene filas con al
menos 10 valores no nulos


print('Número de filas:', df.shape[0])                                      #Imprimir número de
columnas y número de filas del dataframe posterior a esta primer limpieza
print('Número de columnas:', df.shape[1])
```

```
Número de filas: 1048548

Número de columnas: 45
```

Vemos que se redujeron el número de columnas y el número de filas en 18 y 25 respectivamente

1.2 Valores Faltantes

```
df.isnull().sum()*100/len(df)
```

	0
SUCURSAL	0.003147
ESTADO_SUCURSAL	0.002289
CLAVE_OPERACION	0.003815
OPERACION	0.003910
PARTIDA	0.003529
ORIGEN	0.003624
DESCRIPCION_PARTIDA	0.011254
GRAMAJE	10.224787
KILATAJE	17.366077
AVALUO_COMPLEMENTARIO	12.668352
FACTOR_HECHURA	10.223738
FACTOR	10.224596
VALOR_MONTE	0.029279
VALOR_MONTE_ACTUALIZADO	19.302179
AVALUO_COMERCIAL	10.925182
PRESTAMO	0.028897
PRECIO_VENTA_INICIAL	0.029183
PRECIO_VENTA_FINAL	0.029565
FECHA_EMPENO	0.030995
FECHA_COMERCIALIZACION	0.031186
VALOR_ANCLA_ORO	19.304277
RAMO	0.031377
SUBRAMO	0.032616
REFRENDOS_REALIZADOS	0.031854
INCREMENTO	18.252730
DESPLAZAMIENTO_COMERCIAL	18.257403
VALUADOR	2.709361
FECHA_HORA_MOV	0.038625
DEMASIA	2.747222
INTERES	2.859663
INTERESALMONEDA	14.085928

Interpretaciones

Posterior a la eliminación de columnas y filas, todavía podemos observar que las columnas COM_EXHIBICION y FECHA_MAX_DEP_RECUP tienen el 71% y 36% de valores faltantes, por lo que procedemos a eliminar las columnas. Adicional, la columna num_particion se deriva de la columna FECHA_CARGA por lo que también se procede a eliminar.

```
df.drop(['COM_EXHIBICION','FECHA_MAX_DEP_RECUP','num_particion'], axis=1,inplace=True)
```

```
                                                                    #Imprimir número de
columnas y número de filas del dataframe posterior a esta primer limpieza
print('Número de filas:', df.shape[0])
print('Número de columnas:', df.shape[1])
```

```
Número de filas: 1048548
Número de columnas: 42
```

1.3 Asignación de tipo de dato a cada variable

Un punto importante para destacar es que el tipo de dato de cada columna está por default como "objeto", lo que haremos a continuación será asignar el tipo de datos que está de acuerdo con la naturaleza correcta de los datos y de acuerdo con el negocio.

```
                                                                    #Diccionario con
columnas y tipo de dato correcto
dicc = {
    'SUCURSAL': 'str',
    'ESTADO_SUCURSAL': 'str',
    'CLAVE_OPERACION': 'str',
    'OPERACION': 'str',
    'PARTIDA': 'str',
    'ORIGEN': 'str',
    'DESCRIPCION_PARTIDA': 'str',
    'GRAMAJE': 'float',
    'KILATAJE': 'int',
    'AVALUO_COMPLEMENTARIO': 'float',
    'FACTOR_HECHURA': 'str',
    'FACTOR': 'str',
    'VALOR_MONTE': 'float',
    'VALOR_MONTE_ACTUALIZADO': 'float',
    'AVALUO_COMERCIAL': 'float',
    'PRESTAMO': 'float',
    'PRECIO_VENTA_INICIAL': 'float',
    'PRECIO_VENTA_FINAL': 'float',
    'FECHA_EMPENO': 'datetime',
    'FECHA_COMERCIALIZACION': 'datetime',
    'VALOR_ANCLA_ORO': 'float',
    'RAMO': 'str',
    'SUBRAMO': 'str',
    'REFRENDOS_REALIZADOS': 'float',
```

```
    'INCREMENTO': 'int',
    'DESPLAZAMIENTO_COMERCIAL': 'int',
    'VALUADOR': 'str',
    'FECHA_HORA_MOV': 'datetime',
    'DEMASIA':'float',
    'INTERES':'float',
    'INTERESALMONEDA':'float',
    'DES_EXT':'float',
    'IMPORTE_VENTA':'float',
    'PRODUCTO':'str',
    'TASA_OFERTA':'float',
    'CANAL':'str',
    'DIAS_ALMONEDA': 'float',
    'RANGO_DIAS_ALMONEDA': 'str',
    'PRECIO_VENTA_FINAL_SID': 'float',
    'TIPO_PRENDA': 'str',
    'FCH_CARGA': 'datetime',
    'SALDO_INSOLUTO': 'float',
    'FECHA_CARGA': 'datetime'
}
                                                                                #Convertir los
tipos de datos
for col, tipo in dicc.items():
  if tipo in ['int', 'float']:                                                  # Manejar valores
numericos
    try:
      df[col] = pd.to_numeric(df[col], errors='coerce')                         # Convertir a tipo
numerico, invalid values become NaN
    except ValueError:
      print(f"Could not convert column '{col}' to {tipo}. Skipping...")


  elif tipo == 'datetime':
    try:                                                                        # Manejar fechas
      df[col] = pd.to_datetime(df[col], errors='coerce')                        # Convert to
datetime, invalid values become NaT
    except ValueError:
      print(f"Could not convert column '{col}' to {tipo}. Skipping...")
  else:                                                                         # Manejar strings
    df[col] = df[col].astype(tipo)
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1048550 entries, 0 to 1048574
Data columns (total 43 columns):
 #   Column                      Non-Null Count    Dtype
---  ------                      --------------    -----
 0   SUCURSAL                    1048550 non-null  object
 1   ESTADO_SUCURSAL             1048550 non-null  object
 2   CLAVE_OPERACION             1048550 non-null  object
 3   OPERACION                   1048550 non-null  object
 4   PARTIDA                     1048550 non-null  object
 5   ORIGEN                      1048550 non-null  object
 6   DESCRIPCION_PARTIDA         1048550 non-null  object
 7   GRAMAJE                     941382 non-null   float64
 8   KILATAJE                    866407 non-null   float64
 9   AVALUO_COMPLEMENTARIO       915659 non-null   float64
 10  FACTOR_HECHURA              1048550 non-null  object
 11  FACTOR                      1048550 non-null  object
 12  VALOR_MONTE                 1048150 non-null  float64
 13  VALOR_MONTE_ACTUALIZADO     846069 non-null   float64
 14  AVALUO_COMERCIAL            933960 non-null   float64
 15  PRESTAMO                    1048156 non-null  float64
 16  PRECIO_VENTA_INICIAL        1048151 non-null  float64
 17  PRECIO_VENTA_FINAL          1048183 non-null  float64
 18  FECHA_EMPENO                411402 non-null   datetime64[ns]
 19  FECHA_COMERCIALIZACION      394081 non-null   datetime64[ns]
 20  VALOR_ANCLA_ORO             846087 non-null   float64
 21  RAMO                        1048550 non-null  object
 22  SUBRAMO                     1048550 non-null  object
 23  REFRENDOS_REALIZADOS        1048177 non-null  float64
 24  INCREMENTO                  857142 non-null   float64
 25  DESPLAZAMIENTO_COMERCIAL    857081 non-null   float64
 26  VALUADOR                    1048550 non-null  object
 27  FECHA_HORA_MOV              456683 non-null   datetime64[ns]
 28  DEMASIA                     1019725 non-null  float64
 29  INTERES                     1018527 non-null  float64
 30  INTERESALMONEDA             900768 non-null   float64
 31  DES_EXT                     1008605 non-null  float64
 32  IMPORTE_VENTA               1048148 non-null  float64
 33  PRODUCTO                    1048550 non-null  object
 34  TASA_OFERTA                 1048095 non-null  float64
 35  CANAL                       1048550 non-null  object
 36  DIAS_ALMONEDA               1048090 non-null  float64
 37  RANGO_DIAS_ALMONEDA         1048550 non-null  object
 38  PRECIO_VENTA_FINAL_SID      1048088 non-null  float64
 39  TIPO_PRENDA                 1048550 non-null  object
 40  FCH_CARGA                   519637 non-null   datetime64[ns]
 41  SALDO_INSOLUTO              1048038 non-null  float64
 42  FECHA_CARGA                 1048079 non-null  datetime64[ns, UTC]
dtypes: datetime64[ns, UTC](1), datetime64[ns](4), float64(22), object(16)
memory usage: 352.0+ MB
```

Vamos a revisar los valores únicos por columna

```
df.nunique()
```

	0
SUCURSAL	445
ESTADO_SUCURSAL	154
CLAVE_OPERACION	110
OPERACION	100
PARTIDA	1036646
ORIGEN	107
DESCRIPCION_PARTIDA	934954
GRAMAJE	4407
KILATAJE	111
AVALUO_COMPLEMENTARIO	3043
FACTOR_HECHURA	157
FACTOR	130
VALOR_MONTE	38651
VALOR_MONTE_ACTUALIZADO	37413
AVALUO_COMERCIAL	41637
PRESTAMO	28432
PRECIO_VENTA_INICIAL	41434
PRECIO_VENTA_FINAL	43197
FECHA_EMPENO	629
FECHA_COMERCIALIZACION	529
VALOR_ANCLA_ORO	1488
RAMO	96
SUBRAMO	71
REFRENDOS_REALIZADOS	54
INCREMENTO	100
DESPLAZAMIENTO_COMERCIAL	41
VALUADOR	856
FECHA_HORA_MOV	98

Interpretaciones

Podemos confirmar que las variables ahora ya cuentan con el tipo de dato correcto asignado y revisamos la cantidad de valores únicos por columna.

1.4 Imputación de datos perdidos o inexistentes

```
numeric_feat =df.select_dtypes(include=['int64', 'float64']).columns            # seleccionamos las columnas con tipo de dato numérico
cat_var_feat = df.select_dtypes(include=['object']).columns                     # seleccionamos las columns con tipo de dato categórico

df[numeric_feat] = df[numeric_feat].apply(lambda x: x.fillna(x.median()))       # en las variables numéricas decidimos aplicar la imputación de mediana, ya que las distribuciones están sesgadas a la izquierda mayormente
df[cat_var_feat] = df[cat_var_feat].apply(lambda x: x.fillna(x.mode()[0]))      # decidimos aplicar imputación de moda a las variables categóricas
```

```
df.isnull().sum()*100/len(df)
```

	0
SUCURSAL	0.000000
ESTADO_SUCURSAL	0.000000
CLAVE_OPERACION	0.000000
OPERACION	0.000000
PARTIDA	0.000000
ORIGEN	0.000000
DESCRIPCION_PARTIDA	0.000000
GRAMAJE	0.000000
KILATAJE	0.000000
FACTOR_HECHURA	0.000000
FACTOR	0.000000
VALOR_MONTE	0.000000
VALOR_MONTE_ACTUALIZADO	0.000000
AVALUO_COMERCIAL	0.000000
PRESTAMO	0.000000
PRECIO_VENTA_INICIAL	0.000000
PRECIO_VENTA_FINAL	0.000000
FECHA_EMPENO	60.764600
FECHA_COMERCIALIZACION	62.416504
VALOR_ANCLA_ORO	0.000000
RAMO	0.000000
SUBRAMO	0.000000
REFRENDOS_REALIZADOS	0.000000
INCREMENTO	0.000000
DESPLAZAMIENTO_COMERCIAL	0.000000
VALUADOR	0.000000
FECHA_HORA_MOV	56.446152
DEMASIA	0.000000
INTERES	0.000000
INTERESALMONEDA	0.000000
DES_EXT	0.000000

Interpretaciones

Interpretación. Podemos observar que los datos faltantes únicamente ya corresponden a las fechas, las cuales vamos a determinar más adelante el plan de acción con las mismas.

1.5 Evaluación de correlaciones entre variables numéricas

```
df_numericas =
df.select_dtypes(include=['number'])                                                    #
Selecciona solo las columnas numericas
correlation_matrix =
df_numericas.corr()                                                                      #
Calcula la matriz de correlación
plt.figure(figsize=(14,
10))                                                                                  # Ajusta
tamaño según número de variables

sns.heatmap(correlation_matrix, cmap='coolwarm', annot=True, fmt=".2f",
linewidths=0.5)                                  # Crea el mapa de calor
plt.title("Matriz de correlación entre variables
numéricas")                                                          # Título
plt.xticks(rotation=45,
ha='right')                                                                           # Rotación
de etiquetas
plt.yticks(rotation=0)
            # Rotación de etiquetas
plt.tight_layout()
            # Ajusta el espaciado
plt.show()
```

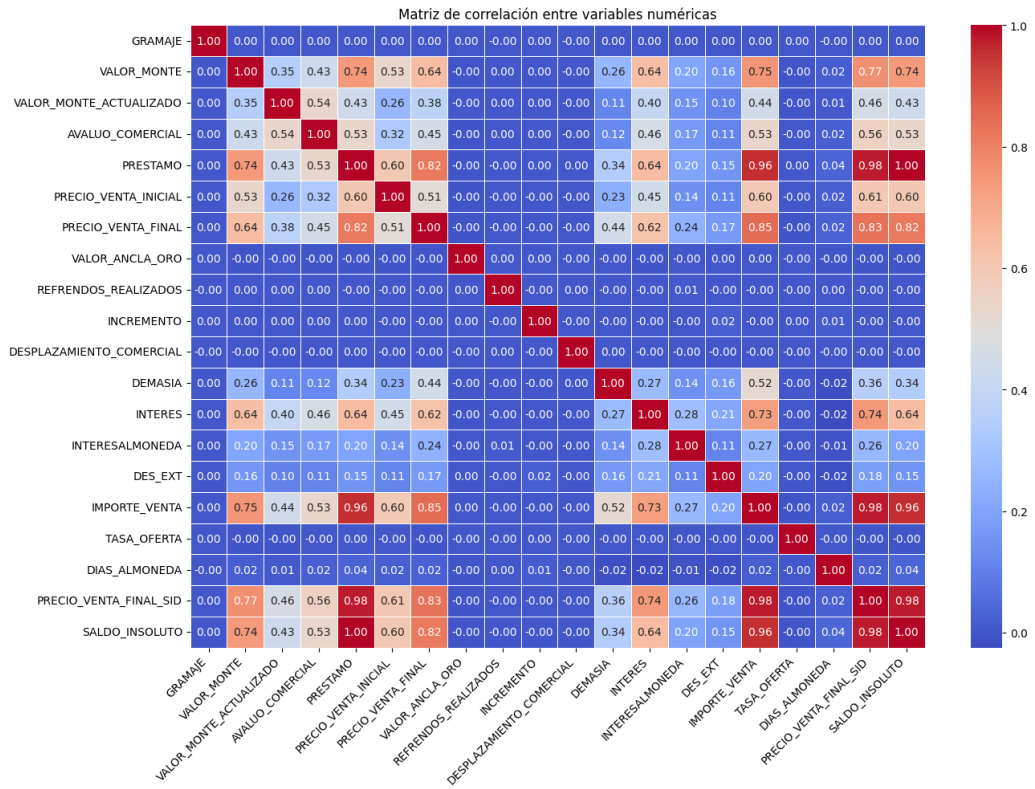

```python
df_numericas = df.select_dtypes(include=['number'])
corr = df_numericas.corr()

correlation_threshold = 0.8


positive_correlations = corr[corr > correlation_threshold].stack().reset_index()
positive_correlations.columns = ['Variable 1', 'Variable 2', 'Correlation']
positive_correlations = positive_correlations[positive_correlations['Variable 1'] != positive_correlations['Variable 2']]

negative_correlations = corr[corr < -correlation_threshold].stack().reset_index()
negative_correlations.columns = ['Variable 1', 'Variable 2', 'Correlation']
negative_correlations = negative_correlations[negative_correlations['Variable 1'] != negative_correlations['Variable 2']]

print("Correlaciones Positivas Fuertes (> 0.8):")
print(positive_correlations.sort_values(by='Correlation', ascending=False))

print("\ Correlaciones Negativas Fuertes (< -0.8):")
print(negative_correlations.sort_values(by='Correlation', ascending=True))
```

```python
# Calcular la matriz de correlación

# Umbral de correlación


# Extraer los pares de variables con correlaciones mayor al umbral
# Renombrar las columnas del resultado
# Eliminar correlaciones redundatnes entre la misma variable

# Extraer solo los pares de variables con correlacion menor que el umbral negativo

# Eliminar autocorrelaciones

# Imprime las correlaciones positivas y negativas
```

```
Correlaciones Positivas Fuertes (> 0.7):
                Variable 1              Variable 2  Correlation
8                PRESTAMO          SALDO_INSOLUTO     0.999938
35         SALDO_INSOLUTO                PRESTAMO     0.999938
26          IMPORTE_VENTA  PRECIO_VENTA_FINAL_SID     0.978961
32  PRECIO_VENTA_FINAL_SID           IMPORTE_VENTA     0.978961
34  PRECIO_VENTA_FINAL_SID          SALDO_INSOLUTO     0.978655
38         SALDO_INSOLUTO  PRECIO_VENTA_FINAL_SID     0.978655
7                PRESTAMO  PRECIO_VENTA_FINAL_SID     0.978618
30  PRECIO_VENTA_FINAL_SID                PRESTAMO     0.978618
23           IMPORTE_VENTA                PRESTAMO     0.959437
6                PRESTAMO           IMPORTE_VENTA     0.959437
37         SALDO_INSOLUTO           IMPORTE_VENTA     0.959403
27          IMPORTE_VENTA          SALDO_INSOLUTO     0.959403
24          IMPORTE_VENTA      PRECIO_VENTA_FINAL     0.846221
12     PRECIO_VENTA_FINAL           IMPORTE_VENTA     0.846221
31  PRECIO_VENTA_FINAL_SID      PRECIO_VENTA_FINAL     0.832834
13     PRECIO_VENTA_FINAL  PRECIO_VENTA_FINAL_SID     0.832834
36         SALDO_INSOLUTO      PRECIO_VENTA_FINAL     0.816142
14     PRECIO_VENTA_FINAL          SALDO_INSOLUTO     0.816142
5                PRESTAMO      PRECIO_VENTA_FINAL     0.816018
10     PRECIO_VENTA_FINAL                PRESTAMO     0.816018
\ Correlaciones Negativas Fuertes (< -0.7):
Empty DataFrame
Columns: [Variable 1, Variable 2, Correlation]
Index: []
```

Interpretaciones

Después de obtener los resultados de las correlaciones, se identifican que todas las correlaciones fuertes encontraras son positivas mayores a 0.7 No se detectaron correlaciones negativas fuetes y en general se indica que algunas variables tienen relaciones lineales muy estrechas, probablemente porque miden lo mismo o tienen aspectos muy similares de una transacción. Por ejemplo, PRESTAMO y SALDO_INSOLUTO tiene una correlación de 0.99 donde prácticamente son la misma variable, usarlas juntas en un modelo puede causar colinealidad, lo cual afecta negativamente la estabilidad del modelo por lo cual solo una de dichas variables debe conservarse.

1.6 Transformación de variables numéricas

Nuestra variable de salida u objetivo se denomina DIAS_ALMONEDA, que son los días que transcurren entre que llega el artículo y la fecha de movimiento (venta). Vamos a observar su distribución.

```
sample_df = df.sample(100000, random_state=42)                                    # Muestra aleatoria de
10,000 registros
sns.histplot(sample_df, x='DIAS_ALMONEDA', hue='RANGO_DIAS_ALMONEDA')
```

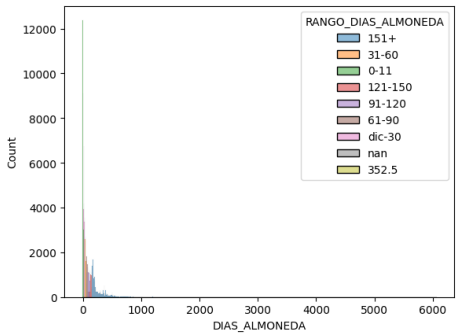

Interpretaciones

Podemos visualizar que el rango de la variable objetivo no tiene una distribución normal, y efectivamente gran parte de las observaciones se encuentra en un rango de más de 151 días, lo que nos demuestra la lenta rotación de artículos.

```
sample_df = sample_df[sample_df['DIAS_ALMONEDA'] >=0]                             # Filtrar solo los
valores positivos
sample_df = sample_df.dropna(subset=['DIAS_ALMONEDA'])                            # Eliminar filas con
valores faltantes en 'DIAS_ALMONEDA'


sample_df['DIAS_ALMONEDA_LOG'] = np.log1p(sample_df['DIAS_ALMONEDA'])             # Aplicar logaritmo a la
columna 'DIAS_ALMONEDA'
sns.histplot(sample_df, x='DIAS_ALMONEDA_LOG', hue='RANGO_DIAS_ALMONEDA')
plt.xlabel('Log(DIAS_ALMONEDA)')                                                   # Etiqueta del eje x
plt.ylabel('Frecuencia')                                                           # Etiqueta del eje y
plt.title('Distribución de DIAS_ALMONEDA')                                         # Título del gráfico
plt.show()
```

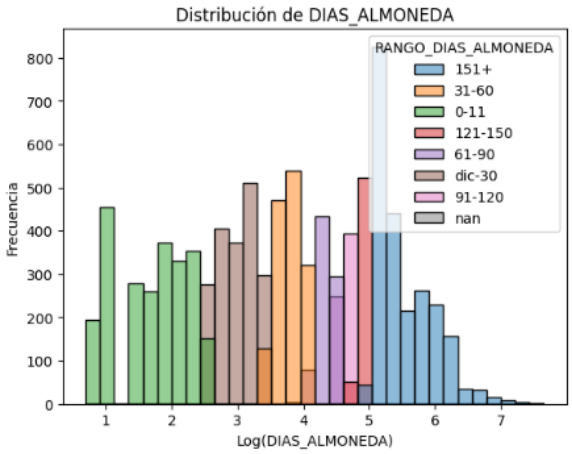

Interpretaciones

La variable DIAS_ALMONEDA representa el número de días que un artículo ha permanecido en inventario, y presenta una distribución altamente sesgada a la derecha, donde la mayoría de los valores se concentran cerca de cero y existen valores extremos mucho mayores. Para abordar el sesgo se aplicó una transformación logarítmica que reduce el impacto de valores extremos, viendo que la distribución sea más simétrica y adecuada para el modelo.

A continuación, vamos a revisar las distribuciones de nuestras variables numéricas para revisar si aplica el escalamiento y transformación.

```
num_var_list =
['DIAS_ALMONEDA','GRAMAJE','VALOR_MONTE','VALOR_MONTE_ACTUALIZADO','AVALUO_COMERCIAL','PRESTAMO',
'PRECIO_VENTA_INICIAL','PRECIO_VENTA_FINAL','VALOR_ANCLA_ORO',
                'REFRENDOS_REALIZADOS']
```

```
num_var_list_2 =
['INCREMENTO','DESPLAZAMIENTO_COMERCIAL','DEMASIA','INTERES','INTERESALMONEDA','DES_EXT','IMPORTE_VENTA','
TASA_OFERTA','PRECIO_VENTA_FINAL_SID',
                'SALDO_INSOLUTO']
```

```
sns.set(rc={'figure.figsize':(35,5)})
fig, axes = plt.subplots(1,10)
for k in range(0,10):
# Datos originales
  plt.subplot(1,10, k+1)

  Transf0 = sample_df[num_var_list[k]]
  sns.histplot(Transf0)
```

```
  plt.xlabel(num_var_list[k])
  if k == 0:
    plt.ylabel('Originales')

plt.show()
```

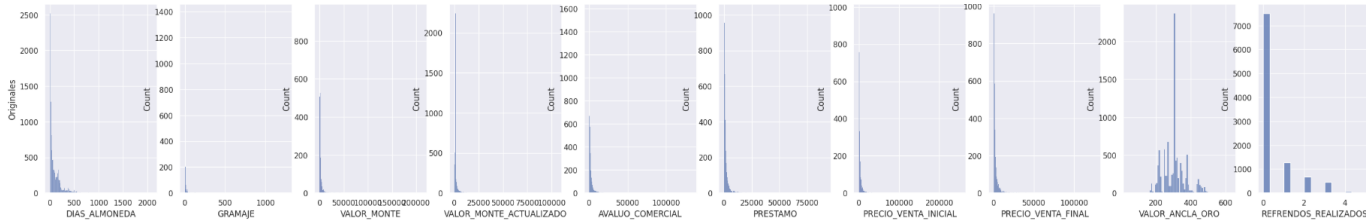


```
sns.set(rc={'figure.figsize':(35,5)})
fig, axes = plt.subplots(1,10)
for k in range(0,10):
# Datos originales
  plt.subplot(1,10, k+1)

  Transf0 = sample_df[num_var_list_2[k]]
  sns.histplot(Transf0)
  plt.xlabel(num_var_list_2[k])
  if k == 0:
    plt.ylabel('Originales')

plt.show()
```

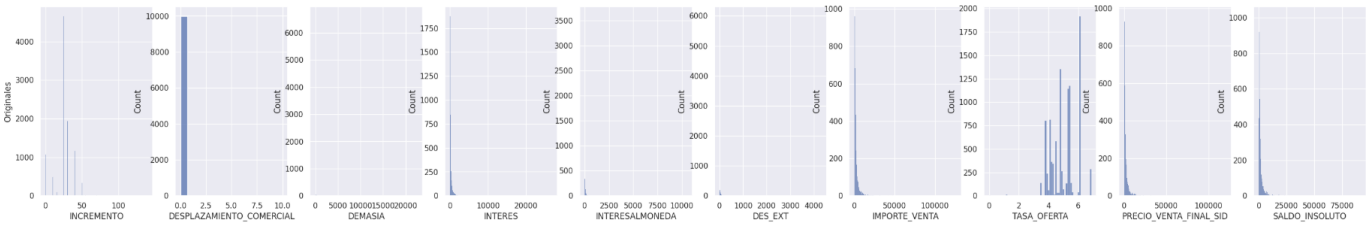

Interpretaciones

Podemos observar que prácticamente todas las variables numéricas cuentan con un sesgo a la izquierda, por lo que primero vamos a aplicar es una transformación Yeo-Johnson,que se puede utilizar en variables con valores cero y negativos, así como valores positivos. Posteriormente aplicaremos un escalamiento Min-Max.

```
df_1 = df.copy()
transformer = PowerTransformer(method="yeo-johnson")
transformer.fit(df_1[['DIAS_ALMONEDA','GRAMAJE','VALOR_MONTE','VALOR_MONTE_ACTUALIZADO','AVALUO_COMERCIAL'
,'PRESTAMO', 'PRECIO_VENTA_INICIAL','PRECIO_VENTA_FINAL','VALOR_ANCLA_ORO',
```

```
                'REFRENDOS_REALIZADOS','INCREMENTO','DESPLAZAMIENTO_COMERCIAL','DEMASIA','INTERES','INTERESALMONEDA','DES_EXT','IMPORTE_VENTA','TASA_OFERTA','PRECIO_VENTA_FINAL_SID',
                'SALDO_INSOLUTO']])
transf = transformer.transform(df_1[['DIAS_ALMONEDA','GRAMAJE','VALOR_MONTE','VALOR_MONTE_ACTUALIZADO','AVALUO_COMERCIAL','PRESTAMO', 'PRECIO_VENTA_INICIAL','PRECIO_VENTA_FINAL','VALOR_ANCLA_ORO',
                'REFRENDOS_REALIZADOS','INCREMENTO','DESPLAZAMIENTO_COMERCIAL','DEMASIA','INTERES','INTERESALMONEDA','DES_EXT','IMPORTE_VENTA','TASA_OFERTA','PRECIO_VENTA_FINAL_SID',
                'SALDO_INSOLUTO']])
transf_df = pd.DataFrame(transf)
transf_df.columns = ['DIAS_ALMONEDA','GRAMAJE','VALOR_MONTE','VALOR_MONTE_ACTUALIZADO','AVALUO_COMERCIAL','PRESTAMO','PRECIO_VENTA_INICIAL','PRECIO_VENTA_FINAL','VALOR_ANCLA_ORO',
                'REFRENDOS_REALIZADOS','INCREMENTO','DESPLAZAMIENTO_COMERCIAL','DEMASIA','INTERES','INTERESALMONEDA','DES_EXT','IMPORTE_VENTA','TASA_OFERTA','PRECIO_VENTA_FINAL_SID',
                'SALDO_INSOLUTO']
transf_df
```

	DIAS_ALMONEDA	GRAMAJE	VALOR_MONTE	VALOR_MONTE_ACTUALIZADO	AVALUO_COMERCIAL	PRESTAMO	PRECIO_VENTA_INICIAL	PRECIO_VENTA_FINAL	VALOR_ANCLA_ORO	REFRENDOS_REALIZADOS	INCREMENTO	DESPLAZAMIENTO_COMERCIAL	DEMASIA	INTERES	INTERESALMONEDA	DES_EXT	IMPORTE_VENTA	TASA_OFERTA	PRECIO_VENTA_FINAL_SID
0	-0.275506	0.112966	-3.512577	-0.023542	-0.074190	0.298810	-0.093272	0.303541	0.085473	-0.573342	0.190203	-0.036407	1.566910	-1.753041	0.185185	-0.813211	0.305842	-1.807014	0.078909
1	-0.275506	-0.033153	-3.512577	-0.023542	-0.074190	-0.176302	-0.607500	0.019726	0.085473	-0.573342	0.190203	-0.036407	1.584149	-1.753041	0.185185	-0.813211	0.021765	-1.807014	-0.391987
2	-0.275506	-0.033153	-3.512577	-0.023542	-0.074190	0.470374	0.084878	0.495719	0.085473	-0.573342	0.190203	-0.036407	1.588855	-1.753041	0.185185	-0.813211	0.497970	-1.807014	0.249564
3	-0.316010	1.593710	-3.512577	-0.023542	-3.807988	-4.583637	1.345075	1.513663	0.085473	-0.573342	0.428410	-0.036407	1.698371	-1.753041	-1.237044	-0.813211	1.512517	-0.112188	-4.629859
4	-0.503825	1.159381	-3.512577	-0.023542	-3.807988	-4.583637	0.108274	0.279152	0.085473	-0.573342	-0.805263	-0.036407	1.652765	-1.753041	-1.241968	-0.813211	0.281447	-0.112188	-4.629859
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1048543	-0.381068	0.028106	0.126076	0.243088	0.231025	0.269136	0.156967	0.327234	-0.444560	1.812555	1.177226	-0.036407	-0.724554	0.569012	1.067352	1.228658	0.329539	0.364351	0.319776
1048544	1.635474	-0.462295	-0.060650	-0.283933	0.024070	-0.104723	-0.053993	0.038414	-0.049881	-0.573342	0.428410	-0.036407	-0.724554	0.308710	-1.249442	-0.813211	0.040482	0.465494	0.038428
1048545	0.618696	-0.511712	-0.289923	-0.423883	-0.229632	-0.190505	-0.326640	-0.230555	-0.741317	1.665453	0.834727	-0.036407	-0.724554	0.213492	-1.249442	-0.813211	-0.229076	-0.451288	-0.215249
1048546	-1.108093	-0.033153	1.046455	-0.023542	-0.074190	0.823978	0.885921	0.906972	0.085473	1.812555	0.190203	-0.036407	1.491592	1.001509	1.078439	1.484623	0.908491	-0.112188	0.868294
1048547	-0.559332	0.798764	0.794424	1.075520	0.974178	0.956950	0.816927	0.983057	-0.288429	1.812555	1.177226	-0.036407	1.398384	0.946514	1.239889	1.508352	0.984346	-0.996974	0.974945

1048548 rows × 20 columns

```
minmax_scale = preprocessing.MinMaxScaler().fit(transf_df[['DIAS_ALMONEDA','GRAMAJE','VALOR_MONTE','VALOR_MONTE_ACTUALIZADO','AVALUO_COMERCIAL','PRESTAMO', 'PRECIO_VENTA_INICIAL','PRECIO_VENTA_FINAL','VALOR_ANCLA_ORO',
                'REFRENDOS_REALIZADOS','INCREMENTO','DESPLAZAMIENTO_COMERCIAL','DEMASIA','INTERES','INTERESALMONEDA','DES_EXT','IMPORTE_VENTA','TASA_OFERTA','PRECIO_VENTA_FINAL_SID',
                'SALDO_INSOLUTO']])
minmax= minmax_scale.transform(transf_df[['DIAS_ALMONEDA','GRAMAJE','VALOR_MONTE','VALOR_MONTE_ACTUALIZADO','AVALUO_COMERCIAL','PRESTAMO', 'PRECIO_VENTA_INICIAL','PRECIO_VENTA_FINAL','VALOR_ANCLA_ORO',
                'REFRENDOS_REALIZADOS','INCREMENTO','DESPLAZAMIENTO_COMERCIAL','DEMASIA','INTERES','INTERESALMONEDA','DES_EXT','IMPORTE_VENTA','TASA_OFERTA','PRECIO_VENTA_FINAL_SID',
                'SALDO_INSOLUTO']])
```

```
minmax_df = pd.DataFrame(minmax)
minmax_df.columns=['DIAS_ALMONEDA','GRAMAJE','VALOR_MONTE','VALOR_MONTE_ACTUALIZADO','AVALUO_COMERCIAL','PRESTAMO', 'PRECIO_VENTA_INICIAL','PRECIO_VENTA_FINAL','VALOR_ANCLA_ORO',
                'REFRENDOS_REALIZADOS','INCREMENTO','DESPLAZAMIENTO_COMERCIAL','DEMASIA','INTERES','INTERESALMONEDA','DES_EXT','IMPORTE_VENTA','TASA_OFERTA','PRECIO_VENTA_FINAL_SID',
                'SALDO_INSOLUTO']
minmax_df
```

	DIAS_ALMONEDA	GRAMAJE	VALOR_MONTE	VALOR_MONTE_ACTUALIZADO	AVALUO_COMERCIAL	PRESTAMO	PRECIO_VENTA_INICIAL	PRECIO_VENTA_FINAL	VALOR_ANCLA_ORO	REFRENDOS_REALIZADOS	INCREMENTO	DESPLAZAMIENTO_COMERCIAL	DEMASIA	INTERES	INTERESALMONEDA	DES_EXT	IMPORTE_VENTA	TASA_OFERTA	PRECIO_VENTA_FINAL_SID	SA
0	0.760825	0.559595	0.000000	0.629372	0.253563	0.465430	0.597813	0.588044	0.514901	0.000000	0.019834	0.0	0.931019	0.000000	0.261773	0.001856	0.617702	0.141763	0.445945	
1	0.760825	0.535296	0.000000	0.629372	0.253563	0.422179	0.558957	0.565969	0.514901	0.000000	0.019834	0.0	0.938024	0.000000	0.261773	0.001856	0.593410	0.141763	0.403291	
2	0.760825	0.535296	0.000000	0.629372	0.253563	0.481048	0.611274	0.602992	0.514901	0.000000	0.019834	0.0	0.939936	0.000000	0.261773	0.001856	0.634131	0.141763	0.461404	
3	0.760149	0.805840	0.000000	0.629372	0.000000	0.020968	0.706498	0.682170	0.514901	0.000000	0.021580	0.0	0.984432	0.000000	0.002262	0.001856	0.720887	0.165903	0.019416	
4	0.757018	0.733612	0.000000	0.629372	0.000000	0.020968	0.613042	0.586147	0.514901	0.000000	0.012539	0.0	0.965902	0.000000	0.001364	0.001856	0.615616	0.165903	0.019416	
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1048543	0.759065	0.545483	0.266519	0.645594	0.274290	0.462729	0.616721	0.589887	0.505984	0.982400	0.027067	0.0	0.000000	0.216875	0.422741	0.759430	0.619729	0.172691	0.467764	
1048544	0.792690	0.463930	0.252842	0.613529	0.260236	0.428695	0.600781	0.567422	0.512624	0.000000	0.021580	0.0	0.000000	0.192563	0.000000	0.001856	0.595011	0.174131	0.442278	
1048545	0.775735	0.455712	0.236049	0.605014	0.243007	0.420886	0.580179	0.546501	0.500992	0.921831	0.024557	0.0	0.000000	0.183670	0.000000	0.001856	0.571960	0.161073	0.419300	
1048546	0.746942	0.535296	0.333934	0.629372	0.253563	0.513237	0.671803	0.634980	0.514901	0.982400	0.019834	0.0	0.900418	0.257269	0.424764	0.854398	0.669236	0.165903	0.517449	
1048547	0.756092	0.673642	0.315473	0.696240	0.324758	0.525342	0.666589	0.640898	0.508610	0.982400	0.027067	0.0	0.862547	0.252132	0.454223	0.863202	0.675722	0.153301	0.527110	

1048548 rows × 20 columns

```
minmax_df_sample = minmax_df.sample(10000, random_state=42)
sns.set(rc={'figure.figsize':(35,5)})
fig, axes = plt.subplots(1,10)
for k in range(0,10):
# Datos originales
  plt.subplot(1,10, k+1)

  Transf2 = minmax_df_sample[num_var_list[k]]
  sns.histplot(Transf2)
  plt.xlabel(num_var_list[k])
  if k == 0:
    plt.ylabel('Yeo-Johnson-Min_Max')

plt.show()
```

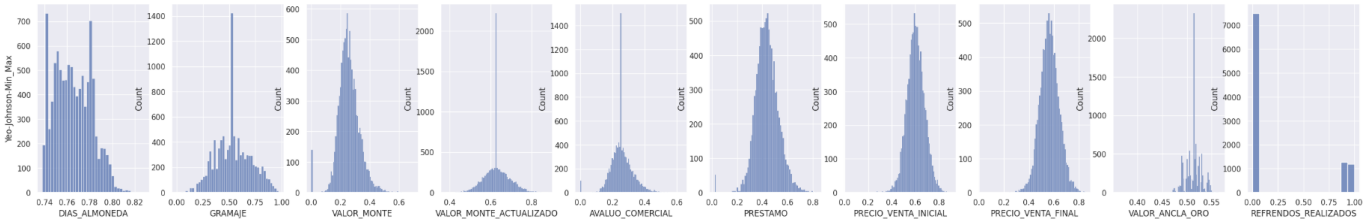


```
sns.set(rc={'figure.figsize':(35,5)})
fig, axes = plt.subplots(1,10)
for k in range(0,10):
# Datos originales
  plt.subplot(1,10, k+1)

  Transf2 = minmax_df_sample[num_var_list_2[k]]
  sns.histplot(Transf2)
  plt.xlabel(num_var_list_2[k])
  if k == 0:
    plt.ylabel('Yeo-Johnson-Min_Max')
plt.show()
```

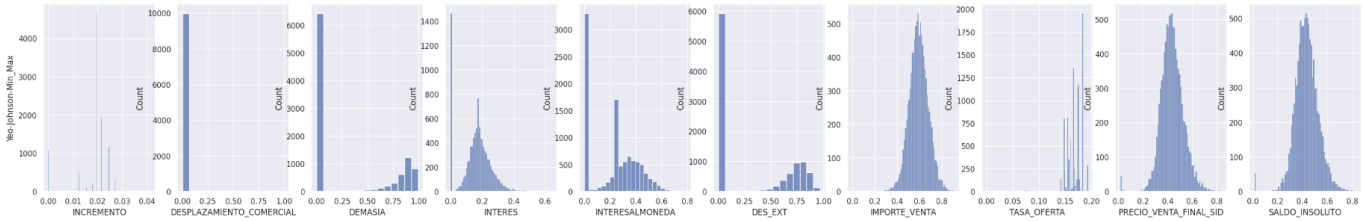

Interpretaciones

Podemos observar que las distribuciones de las variables numéricas considerando nuestra variable target, son prácticamente normales mayormente.

1.7 Transformación de variables categóricas

Antes de iniciar con la transformación de variables categóricas, es importante separar en dos listas las variables con alta cardinalidad y las variables con baja cardinalidad. Vamos a empezar con las de baja cardinalidad.

```
r = df.describe(include=object).T
moda = r['top'].dtype
few_cardinal = r[r['unique'] <= 100].index
few_cardinal_variables = df[few_cardinal]
few_cardinal_variables
```

	ESTADO_SUCURSAL	CLAVE_OPERACION	OPERACION	ORIGEN	KILATAJE	FACTOR_HECHURA	FACTOR	RAMO	SUBRAMO	PRODUCTO	CANAL	RANGO_DIAS_ALMONEDA	TIPO_PRENDA
0	CIUDAD DE MÃ□XICO	VP	Venta al Publico	SIVA	14	Abollado Ligero / Funcional	F3	ALHAJAS	Alhajas	CL	Aprovechamiento Institucion	31-60	ANILLO
1	CIUDAD DE MÃ□XICO	VP	Venta al Publico	MIDAS	nan	nan	nan	ALHAJAS	Diamantes	CL	Aprovechamiento Institucion	31-60	ANILLO
2	CIUDAD DE MÃ□XICO	VP	Venta al Publico	MIDAS	nan	nan	nan	ALHAJAS	Diamantes	CL	Aprovechamiento Institucion	31-60	CHURUMBELA
3	AGUASCALIENTES	VP	Venta al Publico	SIVA	10	Buen Estado Sin Personalizar / Sin Abollar	F4	ALHAJAS	Alhajas	CL	Anticipado Ventanilla	dic-30	COLLAR
4	CIUDAD DE MÃ□XICO	VP	Venta al Publico	SIVA	8	Personalizado	F2	ALHAJAS	Alhajas	CL	Anticipado Ventanilla	dic-30	OTROS
...	...	...	...	...	...	...	...	...	...	...	...	...	...
1048570	YUCATÃ□N	VP	Venta al Publico	SIVA	10	Buen Estado Sin Personalizar / Sin Abollar	F4	ALHAJAS	Alhajas	CL	Cumplido	dic-30	PULSERA
1048571	PUEBLA	VP	Venta al Publico	SIVA	14	Buen Estado Sin Personalizar / Sin Abollar	F4	ALHAJAS	Alhajas	CL	Cumplido	151+	ANILLO
1048572	GUERRERO	VP	Venta al Publico	SIVA	10	Buen Estado Sin Personalizar / Sin Abollar	F4	ALHAJAS	Alhajas	CL	Cumplido	91-120	ANILLO
1048573	QUINTANA ROO	VP	Venta al Publico	MIDAS	nan	nan	nan	ALHAJAS	Diamantes	CL	Cumplido	0-11	BROQUEL
1048574	NUEVO LEÃ□N	VP	Venta al Publico	SIVA	10	Buen Estado Sin Personalizar / Sin Abollar	F4	ALHAJAS	Alhajas	CL	Cumplido	dic-30	ANILLO

1047939 rows × 13 columns

Vamos a visualizar, en gráficos de barra la frecuencia de las categorías de las variables con baja cardinalidad:

```
sample_df_2 = few_cardinal_variables.sample(100000, random_state=42)

# Create subplots
fig, axis = plt.subplots(7, 2, figsize=(20, 30))

# Define the variables to plot
variables = ['ESTADO_SUCURSAL','CLAVE_OPERACION',
```

```
            'OPERACION', 'ORIGEN','KILATAJE',
            'FACTOR_HECHURA', 'FACTOR','RAMO',
            'SUBRAMO', 'PRODUCTO', 'CANAL',
            'RANGO_DIAS_ALMONEDA', 'TIPO_PRENDA']


for i, var in enumerate(variables):
    row = i // 2
    col = i % 2
    ax = axis[row, col]


    top_categories = sample_df_2[var].value_counts().nlargest(20).index
    filtered_data = sample_df_2[sample_df_2[var].isin(top_categories)]

    plot = sns.countplot(x=var, data=filtered_data, ax=ax, order=top_categories)
    plot.set_xticklabels(plot.get_xticklabels(), rotation=60, ha='right', fontsize=8)
    ax.set_title(f'Distribución de {var}', fontsize=10)
    plt.tight_layout(rect=[0,0,1,0.97])

plt.show()
```

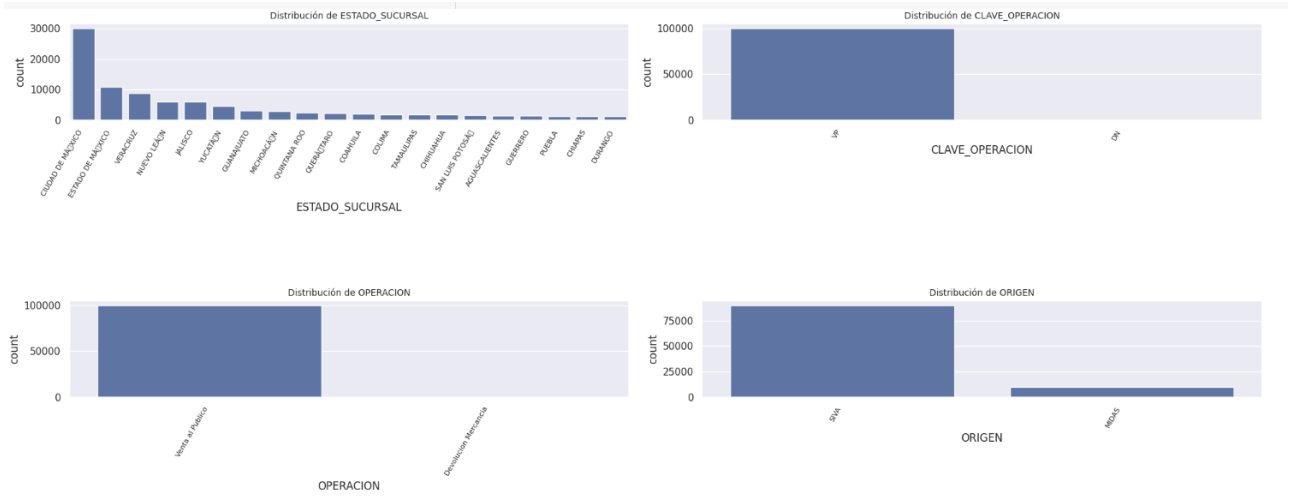

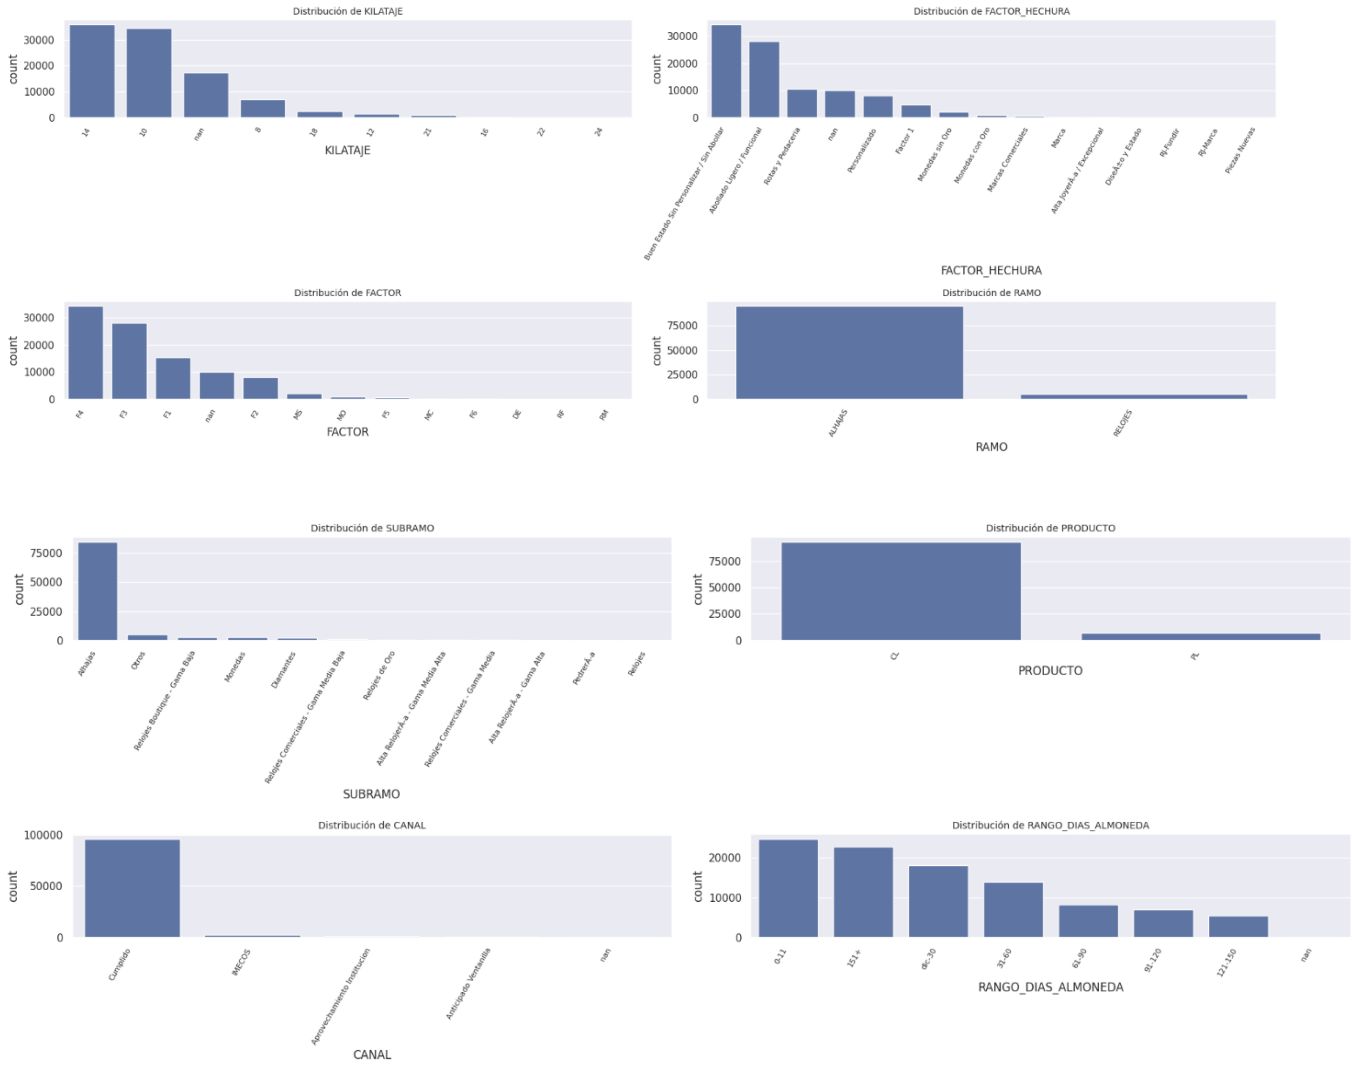

Posteriormente vamos a aplicar la codificación *one hot a las variables de baja cardinalidad. Consideremos que esta codificación agrega más columnas al dataset por cada valor único. En nuestro caso tenemos más variables con baja cardinalidad que alta cardinalidad.

```
encoder = OneHotEncoder(drop='first',sparse_output=False)
encoded_data = encoder.fit_transform(few_cardinal_variables)
onehot_df = pd.DataFrame(encoded_data)
onehot_df.columns = encoder.get_feature_names_out()
onehot_df
```

	ESTADO_SUCURSAL_BAJA CALIFORNIA NORTE	ESTADO_SUCURSAL_BAJA CALIFORNIA SUR	ESTADO_SUCURSAL_CAMPECHE	ESTADO_SUCURSAL_CHIAPAS	ESTADO_SUCURSAL_CHIHUAHUA	ESTADO_SUCURSAL_CIUDAD DE MÃXICO	ESTADO_SUCURSAL_COAHUILA	ESTADO_SUCURSAL_COLIMA	ESTADO_SUCURSAL_DURANGO	ESTADO_SUCURSAL_ESTADO DE MÃXICO	...	TIPO_PRENDA_MONEDA	TIPO_PRENDA_OTROS	TIPO_PRENDA_PANTALLA
0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0
1	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0
2	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0
3	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0
4	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	...	0.0	1.0	0.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1047934	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0
1047935	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0
1047936	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0
1047937	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0
1047938	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0

1047939 rows × 122 columns

Posteriormente vamos a aplicar codificación binaria a las variables con alta cardinalidad, la transformación será BinaryEncoder para que el modelo se más eficiente para evaluar los datos y distribuciones de las variables.

```
high_cardinal = r[r['unique'] > 100].index
highly_cardinal_variables = df[high_cardinal]
highly_cardinal_variables
```

	SUCURSAL	PARTIDA	DESCRIPCION_PARTIDA	VALUADOR
0	1005	181615421	176231504-1 ANILLO TIPO:DAMA DISEÃ□O:CABUJON D...	0
1	1005	181616741	174275433-1 ANILLO ORO AMARILLO 14K PESO 1.60 ...	0
2	1005	181616743	173896016-1 MEDIA CHURUMBELA ORO AMARILLO 14K...	0
3	16	181662772	1 COLLAR TIPO:ROSARIO DISEÃ□O:ESFERAS LISAS D...	1200444
4	278	181809632	1 ACCESORIOS TIPO:LLAVERO DISEÃ□O:GRABADO DE O...	2010538
...	...	...	...	...
1048570	28	175183815	1 PULSERA TIPO:ESLABON DISEÃ□O:LAMINADO DE ORO...	1984026
1048571	229	175186666	1 ANILLO TIPO:DAMA DISEÃ□O:CON SINTETICO DE OR...	2001188
1048572	64	175200563	1 ANILLO TIPO:DAMA DISEÃ□O:CON SINTETICO DE OR...	1500150
1048573	204	175201651	1 PAR BROQUELES ORO AMARILLO 14K PESO 6.00 GR...	2010170
1048574	108	175204537	ANILLO CON SINTETICOS ORO BAJO GRAMOS 8....TOT...	1996182

1047939 rows × 4 columns

```
encoder = BinaryEncoder()
encoded_data= encoder.fit_transform(highly_cardinal_variables)
binary_df = pd.DataFrame(encoded_data)
binary_df.columns = encoder.get_feature_names_out()
binary_df
```

	SUCURSAL_0	SUCURSAL_1	SUCURSAL_2	SUCURSAL_3	SUCURSAL_4	SUCURSAL_5	SUCURSAL_6	SUCURSAL_7	SUCURSAL_8	PARTIDA_0	...	VALUADOR_0	VALUADOR_1	VALUADOR_2	VALUADOR_3	VALUADOR_4	VALUADOR_5	VALUADOR_6	VALUADOR_7	VALUADOR_8	VALUADOR_9
0	0	0	0	0	0	0	0	0	1	0	...	0	0	0	0	0	0	0	0	0	1
1	0	0	0	0	0	0	0	0	1	0	...	0	0	0	0	0	0	0	0	0	1
2	0	0	0	0	0	0	0	0	1	0	...	0	0	0	0	0	0	0	0	0	1
3	0	0	0	0	0	0	0	1	0	0	...	0	0	0	0	0	0	0	0	1	0
4	0	0	0	0	0	0	0	1	1	0	...	0	0	0	0	0	0	0	0	1	1
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1048570	0	1	1	0	0	0	0	1	1	1	...	0	0	1	1	1	0	0	1	0	1
1048571	1	0	0	0	1	0	0	0	1	1	...	0	1	0	1	0	1	1	0	1	0
1048572	0	1	0	1	0	0	0	1	1	1	...	0	0	1	1	1	0	0	0	1	0
1048573	1	0	0	1	0	0	1	1	1	1	...	0	1	1	0	0	0	0	1	0	1
1048574	0	0	1	1	0	0	0	1	1	1	...	0	0	0	1	1	0	0	1	0	0

1047939 rows × 59 columns

1.8 Aplicación de PCA a variables numéricas

La aplicación de Principal Component Analysis, consiste en reducir la dimensionalidad de un dataset para mejorar la eficiencia de un modelo de machine learning como el que estaremos aplicando al problema, es importante mencionar que previo a aplicar el método de PCA, se requiere escalar las variables numéricas, ya que la varianza es sensible a la magnitud de los datos, etapa que ya se realizó anteriormente. Se requiere que mayormente la media sea cero y su varianza de 1.

```
pca = PCA()
minmax_df_projected = pca.fit_transform(minmax_df)
```

```
minmax_df_projected = pd.DataFrame(minmax_df_projected)
minmax_df_projected.head(5)
```

	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19
0	0.263387	-0.234478	-0.129171	0.576532	-0.310339	0.181428	-0.077540	0.098193	-0.038747	0.000128	-0.173005	0.004894	-0.005774	-0.008445	-0.008649	0.012497	-0.003816	-0.000108	-0.000055	0.000361
1	0.264749	-0.238003	-0.206328	0.567677	-0.300926	0.203441	-0.054421	0.074331	-0.014703	0.011194	-0.164544	0.002821	-0.014356	-0.011226	-0.005504	-0.001281	-0.002116	-0.004995	-0.001276	0.001001
2	0.270865	-0.233100	-0.114540	0.578784	-0.337705	0.153219	-0.086785	0.106151	-0.046472	0.004549	-0.176534	0.006965	-0.004591	-0.010551	-0.009325	0.013182	-0.003753	0.000856	-0.000004	0.000263
3	0.239036	-0.249430	-0.463301	0.785787	0.098327	0.393356	0.096768	0.094050	-0.180163	0.520100	0.150694	-0.093987	-0.034716	0.025593	-0.025674	-0.017108	0.005883	-0.012221	-0.003731	-0.000009
4	0.217498	-0.254219	-0.576564	0.740449	0.095749	0.389749	0.110819	0.058874	-0.127094	0.410926	0.123759	-0.050389	-0.030914	0.007563	-0.016593	-0.015087	-0.002643	-0.010510	-0.003695	0.000250

Vamos a visualizar la curva de porcentaje de varianza acumulada y determinar el número mínimo de componentes principales que expliqu más del 90% de varianza.

```
total_components =minmax_df_projected.shape[1]
sns.set_style('white')

plt.plot(np.cumsum(pca.explained_variance_ratio_)*100)
plt.title('PCA Analysis')
plt.xlabel('N-th Principal Component')
plt.ylabel('% Cumulative Variance Explained')
plt.xticks(np.arange(0,total_components,1))
#ax = plt.axes()
#ax.xaxis.grid()

labels = np.cumsum(pca.explained_variance_ratio_)*100
for i in range(total_components):
  plt.text(i,labels[i],str(format(labels[i],'.2f'))+'%')
```

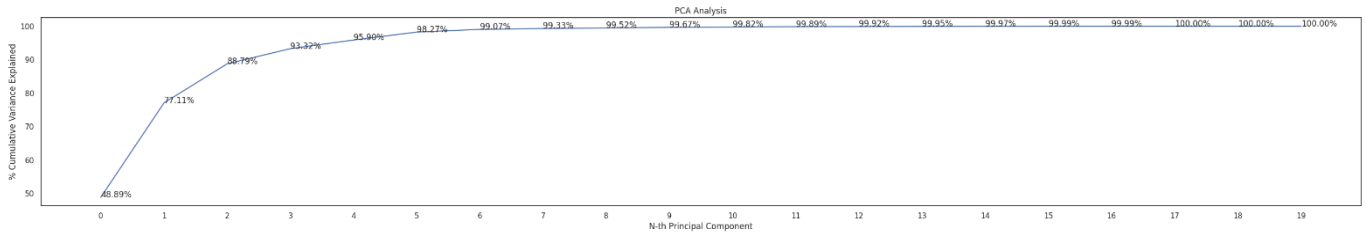

Interpretaciones

Podemos observar el porcentaje de varianza que se explica por cada componente principal. En nuestro caso el componente principal #5 explica más del 98% de varianza de los datos y es el que vamos a ocupar.

```
for i in range(0, total_components):
  print("The percentage of variance explained by principal component", i+1, "is",
format(pca.explained_variance_ratio_[i]*100,'.2f'),'%')
```

```
The percentage of variance explained by principal component 1 is 48.89 %
The percentage of variance explained by principal component 2 is 28.22 %
The percentage of variance explained by principal component 3 is 11.68 %
The percentage of variance explained by principal component 4 is 4.52 %
The percentage of variance explained by principal component 5 is 2.58 %
The percentage of variance explained by principal component 6 is 2.37 %
The percentage of variance explained by principal component 7 is 0.81 %
The percentage of variance explained by principal component 8 is 0.25 %
The percentage of variance explained by principal component 9 is 0.19 %
The percentage of variance explained by principal component 10 is 0.15 %
The percentage of variance explained by principal component 11 is 0.15 %
The percentage of variance explained by principal component 12 is 0.07 %
The percentage of variance explained by principal component 13 is 0.03 %
The percentage of variance explained by principal component 14 is 0.03 %
The percentage of variance explained by principal component 15 is 0.02 %
The percentage of variance explained by principal component 16 is 0.02 %
The percentage of variance explained by principal component 17 is 0.01 %
The percentage of variance explained by principal component 18 is 0.00 %
The percentage of variance explained by principal component 19 is 0.00 %
The percentage of variance explained by principal component 20 is 0.00 %
```

Importante, antes de concatenar el nuevo dataframe con las variables transformadas, escaladas y analizadas con PCA, vamos a separar la variable de salida (DIAS_ALMONEDA) sin las transformaciones y escalamiento, ya que es importante por temas de interpretabilidad conservar la variable en sus unidades originales que son días.

```
y= df['DIAS_ALMONEDA']
```

1.9 Aplicación de PCA a variables numéricas

```
n = 5
#Vamos a seleccionar únicamente los primeros n componentes del PCA y los almacenamos en un nuevo dataframe
new_data = minmax_df_projected[[0,1,2,3,4]]
#Se renombran las columnas del dataframe con los nombres de los componentes principales
new_data.columns = ['PC{}'.format(i) for i in range(1,n+1)]

#Se concatena el dataframe de componentes principales, dataframe codificado one-hot, las variables
binarias (categóricas) y la variable objetivo y

new_data = pd.concat([new_data,onehot_df,binary_df,y],axis=1)
```

```
new_data
```

	PC1	PC2	PC3	PC4	PC5	ESTADO_SUCURSAL_BAJA CALIFORNIA NORTE	ESTADO_SUCURSAL_BAJA CALIFORNIA SUR	ESTADO_SUCURSAL_CAMPECHE	ESTADO_SUCURSAL_CHIAPAS	ESTADO_SUCURSAL_CHIHUAHUA	...	VALUADOR_1	VALUADOR_2	VALUADOR_3	VALUADOR_4	VALUADOR_5	VALUADOR_6	VALUADOR_7	VALUADOR_8	VALUADOR_9	DIAS_ALMONEDA
0	0.263387	-0.234478	-0.129171	0.576532	-0.310339	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	31.0
1	0.264749	-0.238003	-0.206328	0.567677	-0.300926	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	31.0
2	0.270865	-0.233100	-0.114540	0.578784	-0.337705	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	31.0
3	0.239036	-0.249430	-0.463301	0.785787	0.098327	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	29.0
4	0.217498	-0.254219	-0.576564	0.740449	0.095749	0.0	0.0	0.0	0.0	0.0	...	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	1.0	21.0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
1048570	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	0.0	1.0	1.0	1.0	0.0	0.0	1.0	0.0	1.0	26.0
1048571	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	1.0	0.0	1.0	0.0	1.0	1.0	0.0	1.0	0.0	347.0
1048572	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	0.0	1.0	1.0	1.0	0.0	0.0	0.0	1.0	0.0	111.0
1048573	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	1.0	1.0	0.0	0.0	0.0	0.0	1.0	0.0	1.0	6.0
1048574	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	0.0	0.0	1.0	1.0	0.0	0.0	1.0	0.0	0.0	19.0

1048575 rows × 187 columns

Conclusiones

La fase de preparación de los datos representó un paso clave dentro del enfoque metodológico CRISP-ML, ya que permitió transformar el conjunto de datos original en una versión más limpia, estructurada y adecuada para su posterior modelado. Este proceso incluyó diversas tareas como la imputación de valores faltantes, la transformación de variables numéricas mediante técnicas logarítmicas, y la codificación de variables categóricas a través de One-Hot Encoding. Estas acciones permitieron optimizar la representación de los datos sin comprometer su valor analítico.

Adicionalmente, se llevó a cabo un análisis de correlaciones que permitió identificar relaciones lineales fuertes entre variables numéricas, lo cual facilitó la detección de redundancias y la toma de decisiones informadas respecto a la selección de atributos relevantes. Como complemento, se implementó Análisis de Componentes Principales (PCA) como estrategia de reducción de dimensionalidad, conservando la mayor varianza posible en un conjunto reducido de componentes representativos.

En conjunto, esta fase no solo mejoró la calidad del dataset desde el punto de vista técnico y estadístico, sino que también sentó las bases para construir modelos predictivos más eficientes, robustos y generalizables, en línea con los objetivos del ciclo de vida del aprendizaje automático propuesto por CRISP-ML.